

Desigualdade Educacional no ENEM: quais fatores socioeconômicos mais impactam o desempenho do estudante?

Carla Moreno Barbosa Nascimento¹

¹Programa de Pós-Graduação em Informática (PPGI)
Universidade Federal do Rio de Janeiro (UFRJ) – Rio de Janeiro – RJ – Brazil

carlamoreno@ic.ufrj.br

Abstract. *The Brazilian National High School Exam (ENEM) is the main entry point to higher education in Brazil and concentrates millions of candidates each year. Its scores, however, are not produced in a socioeconomic vacuum: family income, school type, race, and geographic region are factors that have been historically associated with educational performance. This work uses the public microdata released by the National Institute of Educational Studies and Research (INEP) to investigate which socioeconomic factors are most strongly related to candidates performance, and whether these relationships remained stable across the 2020-2023 editions of the exam.*

Resumo. *O Exame Nacional de Ensino Médio (ENEM) é a principal porta de entrada para o ensino superior no Brasil e atrai milhões de candidatos a cada ano. Suas notas, no entanto, não são determinadas em um vácuo socioeconômico: renda familiar, tipo de escola, raça e região geográfica são fatores que têm sido historicamente associados ao desempenho escolar. Este trabalho utiliza os microdados públicos divulgados pelo Instituto Nacional de Estudos e Pesquisas Educacionais (INEP) para investigar quais fatores socioeconômicos estão mais fortemente relacionados ao desempenho dos candidatos e se essas relações se mantiveram estáveis ao longo das edições de 2020 a 2023 do exame.*

1. Introdução

O Exame Nacional do Ensino Médio (ENEM), criado em 1998, se tornou o principal mecanismo de acesso ao ensino superior público brasileiro. Por meio de programas como o Sistema de Seleção Unificada (SiSU), o Programa Universidade para Todos (ProUni) e o Fundo de Financiamento Estudantil (FIES), o desempenho de um candidato no ENEM determina, em larga medida, suas oportunidades educacionais e, consequentemente, suas trajetórias profissional e socioeconômica.

Embora idealmente o ENEM deva mensurar o conhecimento adquirido ao longo do ensino médio, em um país com uma grande desigualdade social como o Brasil, o desempenho dos candidatos parece ser fortemente influenciado por fatores que estão fora de seu controle individual. Levanta-se uma questão central: fatores socioeconômicos — renda familiar, tipo de escola (pública/privada), raça, escolaridade dos pais, entre outros — podem ser variáveis associadas às notas obtidas? Em que medida esses dados podem ser relacionados ao desempenho do estudante no exame?

Este trabalho aborda essa questão por meio de uma análise empírica dos microdados públicos do ENEM, disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP). Os microdados contêm, para cada candidato e em formato anonimizado, suas notas nas quatro provas objetivas (Ciências da Natureza, Ciências Humanas, Linguagens e Códigos e Matemática) e na redação, além de um extenso questionário socioeconômico autodeclarado (variáveis Q001 a Q025) e atributos demográficos como faixa etária, sexo, cor/raça, e dados sobre a escola e o município.

1.1. Pergunta de Pesquisa

A pergunta central que norteia este trabalho é:

Quais fatores socioeconômicos presentes nos microdados do ENEM têm maior relação com o desempenho dos candidatos?

Desta pergunta principal derivam três desdobramentos investigativos:

1. Essa relação se mantém estável entre diferentes edições do exame ou apresenta variações temporais relevantes?
2. Existe alguma relação significativas de algum dado demográfico específico?
3. Qual a magnitude das diferenças de desempenho entre grupos socioeconômicos extremos - por exemplo, entre as faixas mais baixa e mais alta de renda, ou entre escolas públicas e privadas?

1.2. Objetivos e Contribuições

O objetivo geral deste trabalho é **identificar e ranquear os fatores socioeconômicos com maior relação com o desempenho dos candidatos no ENEM**, considerando separadamente as cinco notas (quatro provas objetivas e redação). Os objetivos específicos são:

- Realizar análise exploratória dos microdados do ENEM, com foco nas variáveis do questionário socioeconômico e em sua relação com as notas obtidas;
- Investigar a evolução temporal dessas relações ao longo de múltiplas edições do exame;
- Quantificar as diferenças de desempenho entre grupos socioeconômicos - como escola pública e privada, ou faixas extremas de renda - e acompanhar sua evolução no período
- Documentar todo o processo de coleta, preparação, análise e modelagem de forma reprodutível, registrando explicitamente a proveniência dos dados.

As principais contribuições esperadas são: (i) um ranking interpretável dos fatores socioeconômicos com maior peso sobre o desempenho no ENEM; (ii) uma análise temporal indicando se essa desigualdade tem aumentado, se mantido estável ou diminuído entre as edições estudadas; e (iii) um repositório público, versionado e reprodutível, contendo notebooks, dados processados e o registro de proveniência das decisões da análise.

1.3. Organização do Artigo

O restante deste artigo está organizado da seguinte forma:

- **Seção 2 (Trabalhos Relacionados):** discute trabalhos relacionados que investigaram desigualdades educacionais a partir dos microdados do ENEM ou bases similares;
- **Seção 3 (Dataset):** apresenta o conjunto de dados utilizado, sua origem, granularidade e principais variáveis, além de discutir um desafio identificado na edição de 2024;
- **Seção 4 (Metodologia):** detalha a metodologia adotada, incluindo as decisões de pré-processamento e as técnicas estatísticas utilizadas;
- **Seção 5 (Resultados e Discussão):** apresenta os resultados obtidos e a discussão dos achados;
- **Seção 6 (Reprodutibilidade e Proveniência):** descreve as práticas de reprodutibilidade e proveniência adotadas;
- **Seção 7 (Conclusão):** apresenta as considerações finais.

2. Trabalhos Relacionados

Os microdados do ENEM têm sido objeto recorrente de estudos que buscam relacionar o perfil dos candidatos ao seu desempenho. [Franco et al. 2020] aplicaram algoritmos de seleção e classificação de atributos sobre 22 edições do exame (1998-2019), identificando as vinte características que mais contribuem para o alto ou baixo desempenho dos estudantes - entre elas, variáveis socioeconômicas do questionário do participante.

Em uma revisão sistemática da literatura da última década, [Dutra et al. 2023] consolidaram os fatores apontados como mais relevantes pelos estudos que analisam o desempenho no ENEM: renda familiar, idade, sexo, raça e escolaridade dos pais aparecem em maior evidência, seguidos de atributos da escola de origem.

Este trabalho se diferencia dessas iniciativas em dois aspectos. Primeiro, em vez de técnicas de mineração ou modelos preditivos, adota medidas estatísticas simples e interpretáveis (correlação de Spearman e razão de variância explicada), aplicadas de forma uniforme sobre as quatro edições mais recentes com estrutura de tabela única (2020-2023), o que permite comparar diretamente a estabilidade temporal das relações. Segundo, documenta explicitamente a proveniência das decisões de escopo e preparação dos dados - incluindo o impacto da LGPD ([Brasil 2018]) na edição de 2024, discutido na Seção 3.4.

3. Dataset

3.1. Fonte e Caracterização Geral

O conjunto de dados utilizado neste trabalho são os Microdados do ENEM, disponibilizados publicamente pelo [Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) 2024], órgão vinculado ao Ministério da Educação. Os microdados representam o menor nível de desagregação dos dados coletados pelo exame e incluem, para cada candidato inscrito, as informações sobre as provas aplicadas, os gabaritos, as notas obtidas e as respostas ao questionário socioeconômico. A Tabela 1 resume as principais características do conjunto.

Tabela 1. Visão geral do conjunto de dados utilizado.

Atributo	Descrição
Fonte	INEP / Ministério da Educação
URL	https://www.gov.br/inep
Edições analisadas	2020, 2021, 2022 e 2023
Formato dos arquivos	CSV (codificação ISO-8859-1, separador “;”)
Licença	Dados Abertos do Governo Federal
Granularidade	Nível individual (um registro por candidato)
Volume aproximado	3,4 a 5,8 milhões de registros por edição

3.2. Estrutura e Principais Variáveis

Cada registro dos microdados representa um candidato inscrito no exame e contém aproximadamente 76 variáveis, organizadas em quatro grupos principais:

- **Identificação e perfil demográfico:** ano da edição, faixa etária, sexo, estado civil, cor/raça autodeclarada, nacionalidade e situação de conclusão do ensino médio.
- **Características da escola e localização:** tipo de escola (pública/privada), dependência administrativa, localização (urbana/rural), município e unidade da federação da escola e do local de prova.
- **Resultados das provas:** indicador de presença em cada prova, notas nas quatro áreas objetivas e nota da redação, além das cinco competências da redação avaliadas separadamente.
- **Questionário socioeconômico:** 25 variáveis (Q001 a Q025) cobrindo escolaridade dos pais, renda familiar, ocupação dos responsáveis, número de moradores no domicílio e bens de consumo (televisão, computador, internet, automóvel, entre outros).

3.3. Considerações Éticas e Privacidade

Os microdados são publicados em formato anonimizado, sem identificadores diretos dos candidatos. A licença de uso, vinculada à política de Dados Abertos do Governo Federal, permite o uso para fins de pesquisa, desde que respeitada a integridade dos dados e citada a fonte. Nenhuma reidentificação de candidatos é tentada neste trabalho, e todas as análises são conduzidas em nível agregado ou estatístico.

3.4. Desafio Identificado: Edição de 2024 e a LGPD

Durante a fase inicial de exploração dos dados, foi identificado um desafio relevante para o escopo deste trabalho. A partir da edição de 2024, em alinhamento com as exigências da Lei Geral de Proteção de Dados Pessoais (LGPD - Lei nº 13.709/2018) [Brasil 2018], o INEP passou a publicar os microdados em **duas tabelas separadas**: uma contendo os dados demográficos e socioeconômicos dos participantes e outra contendo os resultados das provas. Essas tabelas **não compartilham um identificador comum**, inviabilizando análises individuais que cruzem o perfil socioeconômico de um candidato com seu desempenho efetivo a partir da edição de 2024 - exatamente o tipo de análise que esta pesquisa propõe.

Diante dessa limitação, optou-se por excluir a edição de 2024 do escopo do trabalho. Essa adaptação acabou por ilustrar um aspecto frequente em projetos de ciência de dados: as decisões institucionais sobre a forma de publicação dos dados podem alterar substancialmente o que é possível investigar, ainda que os dados continuem existindo. Esse trabalho registra explicitamente essa decisão como parte da proveniência da análise.

4. Metodologia

A análise foi organizada como um *pipeline* em duas etapas por edição - tratamento e análise - seguidas de uma etapa consolidada que compara as 4 edições. Todo o processamento foi implementado em Python, usando as seguintes bibliotecas:

- `geopandas`: para leitura do GeoJSON das UFs e construção do mapa coroplético por estado,
- `matplotlib`: para geração dos gráficos e figuras,
- `numpy`: para operações numéricas de suporte aos cálculos estatísticos,
- `pandas`: para carregamento, filtragem e manipulação dos microdados,
- `seaborn`: para estilização dos gráficos exploratórios.

4.1. Seleção de Variáveis e Pré-Processamento

Das cerca de 76 variáveis disponíveis nos microdados, foram selecionadas 34, com base no dicionário oficial de cada edição, organizadas em quatro grupos:

- **Identificação e perfil demográfico (9 itens):** número de inscrição, ano da edição, faixa etária, sexo, cor/raça, situação de conclusão do ensino médio, ano de conclusão do ensino médio, tipo de escola, tipo de ensino;
- **Características da escola (4 itens):** município da escola, UF da escola, dependência administrativa, localização (urbana/rural);
- **Resultados das provas (10 itens):** indicador de presença e nota em cada uma das quatro provas objetivas, status da redação e nota da redação;
- **Questionário socioeconômico (10 itens):** escolaridade do pai (Q001) e da mãe (Q002), ocupação do pai (Q003) e da mãe (Q004), número de pessoas na residência (Q005), renda familiar (Q006), número de banheiros (Q008), número de geladeiras (Q012), número de computadores (Q024) e acesso à internet (Q025).

Um 34º indicador, referente à condição de treineiro, foi usado apenas como critério de filtro e descartado em seguida por tornar-se constante, resultando na base final com 33 colunas. A leitura utilizou tipos numéricos compactos (inteiros de 8 bits e ponto flutuante de 32 bits), reduzindo o consumo de memória para viabilizar o processamento de milhões de registros por edição.

Três filtros de qualidade foram aplicados, nesta ordem:

- (i) manutenção apenas dos candidatos presentes nas quatro provas objetivas;
- (ii) remoção dos treineiros, participantes que realizam o exame apenas para autoavaliação, sem fins de ingresso no ensino superior;
- (iii) remoção de duplicatas pelo número de inscrição (nenhuma foi encontrada).

A Tabela 2 mostra o efeito dos filtros em cada edição. As bases resultantes foram exportadas em formato Parquet, com 33 colunas, o que reduziu o tempo de carregamento nas análises de minutos (CSV bruto) para segundos.

Tabela 2. Efeito dos filtros de qualidade sobre o número de registros, por edição.

	2020	2021	2022	2023
Inscritos	5.783.109	3.389.832	3.476.105	3.933.955
Presentes nas 4 provas objetivas	2.588.681	2.238.107	2.344.823	2.678.264
Base final (sem treineiros e duplicatas)	2.242.169	1.870.734	1.927.753	2.166.843

4.2. Métrica de Desempenho

Nas análises anuais, as cinco notas são examinadas separadamente, sob a hipótese de que fatores distintos podem afetar áreas do conhecimento de formas diferentes. **Como métrica-síntese (usada no ranking de fatores e em toda a análise consolidada) adotou-se a média geral**, definida como a média simples das quatro provas objetivas e da redação. Candidatos com redação zerada foram mantidos: a nota zero é um resultado legítimo (prova em branco ou anulada), e sua exclusão introduziria viés de seleção.

4.3. Técnicas de Análise

O questionário socioeconômico é composto majoritariamente por variáveis ordinais: as respostas seguem uma ordem natural ($A < B < C \dots$), como faixas crescentes de renda ou níveis de escolaridade. Essa ordem foi preservada em uma codificação numérica ($A=0$, $B=1$, $\dots$), enquanto categorias sem ordem - como “Não sei” e “Não declarado” - foram convertidas em valores ausentes e excluídas do cálculo par a par. Uma consequência dessa exclusão é que o número de observações varia entre fatores: a renda familiar utiliza quase toda a base, enquanto o tipo de escola considera apenas quem declarou escola pública ou privada.

A força da relação de cada fator com o desempenho foi medida pela correlação de Spearman (ρ), escolhida em vez da correlação de Pearson por três razões: opera sobre postos, o que é adequado a variáveis ordinais; não pressupõe relação linear, apenas monotônica; e é robusta à assimetria das distribuições de notas. Variáveis binárias (sexo; tipo de escola, com pública=0 e privada=1) foram incluídas na mesma matriz. Os fatores foram então ordenados pelo valor absoluto de ρ com a média geral, produzindo o ranking que responde à pergunta de pesquisa - calculado por edição, para avaliar a estabilidade temporal.

A dependência administrativa da escola (federal, estadual, municipal, privada) é nominal, sem ordem natural, e por isso ficou fora da matriz de Spearman. Para medir sua associação com o desempenho utilizou-se o η^2 (razão entre a soma de quadrados entre grupos e a soma de quadrados total), que expressa a fração da variação da média geral explicada pelo pertencimento à rede. Como régua de comparação, o mesmo η^2 foi calculado para as faixas de renda no mesmo recorte de candidatos (apenas aqueles com escola identificada, majoritariamente concluintes do ensino médio).

Por fim, exclusivamente no repositório, foram realizadas comparações diretas entre grupos extremos (por exemplo, candidatos sem geladeira em casa versus com duas ou mais), a fim de analisarmos de forma fragmentada alguns recortes específicos de diferentes realidades.

5. Resultados e Discussão

5.1. Panorama das Edições de 2020 a 2023

A Tabela 3 resume a média geral nas quatro edições, e a Figura 1 mostra a evolução da média de cada prova. A média geral cresceu de 526,4 em 2020 para 543,5 em 2022, com leve recuo em 2023 (540,5). A edição de 2020 destoa das demais (−13,7 pontos em relação à média de 2021-2023), com a maior diferença concentrada na redação (−44,7 pontos). Essa leitura exige cautela: 2020 foi a edição aplicada em plena pandemia, com abstenção recorde - apenas 44,8% dos inscritos compareceram às quatro provas objetivas, contra 66% a 68% nas edições seguintes (Tabela 2) - de modo que o próprio perfil de quem realizou o exame mudou.

Tabela 3. Estatísticas da média geral das cinco notas, por edição.

	2020	2021	2022	2023
Média	526,4	536,2	543,5	540,5
Mediana	515,5	526,8	539,2	537,7
Desvio-padrão	92,4	90,3	89,4	96,5




Figura 1. Evolução da média das notas por prova e da média geral - ENEM 2020-2023.

5.2. Ranking dos Fatores Socioeconômicos

A Figura 2 apresenta o resultado central do trabalho: a correlação de Spearman de cada fator com a média geral, lado a lado nas quatro edições. **A renda familiar (Q006) é o fator de maior relação com o desempenho em todas as edições**, com ρ entre 0,46 e 0,47, seguida do número de computadores em casa (ρ médio de 0,43) e do tipo de escola

(ρ entre 0,40 e 0,43). Os cinco primeiros colocados são os mesmos nos quatro anos, com variações máximas da ordem de 0,02 - ou seja, a resposta à pergunta de pesquisa não depende da edição escolhida.




Figura 2. Correlação de Spearman entre os fatores socioeconômicos e a média geral, por edição - ENEM 2020-2023.

A hierarquia dos fatores tem uma leitura consistente: no topo estão os indicadores de capital econômico - renda, posse de computadores e tipo de escola -, seguidos de perto pelo bloco de escolaridade e ocupação dos pais (ρ entre 0,36 e 0,40), associado ao capital cultural da família. Na base ficam sexo e número de pessoas na residência, com correlações fracas e negativas. Vale notar que “ter internet em casa” (Q025) perdeu força ao longo do período, com ρ caindo de 0,25 em 2020 para 0,19 em 2023: à medida que o acesso se universaliza, a variável separa cada vez menos os grupos - o que não significa que a desigualdade digital tenha desaparecido, pois o número de computadores segue entre os três fatores mais fortes.

A Figura 3 ilustra o padrão do fator mais forte na edição de 2020, representativa das demais: as distribuições de nota deslocam-se monotonicamente para cima a cada faixa

de renda, nas cinco provas - não se trata de um efeito localizado em uma área do conhecimento. O mesmo comportamento monotônico se observa para a posse de computadores: em 2020, candidatos sem computador em casa tiveram média geral de 488,1, contra 612,8 dos que possuíam dois ou mais - diferença de 124,7 pontos.




Figura 3. Distribuição das notas por faixa de renda familiar (Q006) - ENEM 2020.

5.3. Magnitude das Diferenças entre Grupos

A Tabela 4 traduz as correlações em diferenças de pontos entre grupos extremos, respondendo ao terceiro desdobramento da pergunta de pesquisa. As magnitudes são expressivas e estáveis: candidatos de famílias com renda acima de 10 salários mínimos superam os de renda de até 1 salário mínimo em 146 a 165 pontos na média geral, conforme a edição - mais de 1,5 desvio-padrão. Mesmo um item tão básico quanto a geladeira separa os grupos em 92 a 108 pontos, com diferença comparável nas cinco provas, evidenciando que não se trata de um efeito isolado, mas de um gradiente socioeconômico que atravessa todo o exame.

Tabela 4. Diferença de média geral entre grupos extremos, por edição (em pontos).

Comparação (grupo maior – grupo menor)	2020	2021	2022	2023
Renda >10 SM – renda até 1 SM	164,9	149,3	146,0	155,3
Mãe com graduação/pós – mãe que nunca estudou	124,6	113,3	116,5	126,7
2+ geladeiras – nenhuma geladeira	108,4	99,3	92,4	99,0
Escola privada – escola pública	97,4	89,8	89,4	100,3
UF de maior média – UF de menor média	77,6	89,8	77,0	83,5
Com internet – sem internet em casa	59,4	63,0	61,2	62,3

A dimensão regional confirma o padrão. A Figura 4 mostra a média geral por UF da escola em 2020; o desenho se repete nas quatro edições: Minas Gerais lidera em todas

elas (574,9 em 2020; 581,1 em 2023), enquanto o Amazonas aparece consistentemente na base (497,3 em 2020; 497,5 em 2023), com as regiões Sul e Sudeste sistematicamente acima de Norte e Nordeste. Cabe a ressalva de que a UF da escola só é conhecida para os candidatos com escola declarada (537.909 candidatos em 2020, chegando a 721.429 em 2023).




Figura 4. Nota média geral por UF da escola - ENEM 2020.

5.4. Escola Pública versus Privada e o Papel da Rede Federal

A Figura 5 acompanha o gap privada—pública ao longo do período. Na média geral, ele oscilou entre 89,4 e 100,3 pontos - 97,4 em 2020; 89,8 em 2021; 89,4 em 2022; e 100,3 em 2023, o maior valor da série. **Não há tendência de queda:** a distância entre as redes equivale, em todas as edições, a cerca de um desvio-padrão da média geral.




Figura 5. Gap de nota média (privada – pública) por prova e edição - ENEM 2020-2023.

O retrato muda, porém, quando a rede pública é desagregada por dependência administrativa (Figura 6). A rede federal descola das demais redes públicas e se aproxima das privadas: sua mediana ficou entre 8,0 e 23,0 pontos da mediana das privadas (597,8 contra 609,9 em 2020; 601,2 contra 624,3 em 2023), enquanto as estaduais permaneceram cerca de 100 pontos abaixo. Entre os candidatos com escola identificada, a rede administrativa explica sozinha de 24,8% a 26,6% da variação da média geral (η^2) - fração superior à explicada pela faixa de renda no mesmo recorte (21,2% a 23,8%). E, comparando apenas candidatos da mesma faixa de renda, a média das federais supera a das privadas em 12 das 16 combinações edição $\times$ faixa. Esse resultado deve ser lido com cautela, - escolas federais selecionam seus alunos por exame de admissão, um viés de seleção que a estratificação por renda não elimina - mas sugere que a vantagem da rede privada não é inerente à natureza administrativa da escola.




Figura 6. Mediana da média geral por rede administrativa da escola - ENEM 2020-2023.

5.5. Limitações

Quatro limitações principais devem ser consideradas na leitura dos resultados. Primeiro, correlação de Spearman e η^2 medem associação, não causa: renda, escolaridade dos pais, bens do domicílio e rede da escola andam juntos, e separar a contribuição de cada um exigiria um modelo multivariado, fora do escopo deste trabalho. Segundo, o já mencionado viés de seleção das escolas federais. Terceiro, a dependência administrativa e a UF da escola só são conhecidas para os concluintes do ensino médio com escola declarada, subconjunto que não representa todos os candidatos. Quarto, o perfil dos participantes varia entre edições - em especial na edição pandêmica de 2020 -, o que recomenda cautela em leituras finas de tendência temporal. Por fim, todas as variáveis do questionário são autodeclaradas.

6. Reprodutibilidade e Proveniência

Todo o fluxo de análise está organizado em nove *notebooks* disponibilizados no repositório público *Project-DataScience*¹. Para cada edição, um **notebook de tratamento** parte do CSV bruto do INEP, aplica a seleção de colunas e os filtros da Seção 4.1 e exporta a base limpa em Parquet; um **notebook de análise** carrega esse Parquet e gera todas as figuras e estatísticas da edição. Por fim, um **notebook consolidado** carrega os quatro Parquets, produz as comparações 2020-2023 e salva um Parquet consolidado. As figuras deste artigo são exatamente as produzidas por esses notebooks, gravadas automaticamente em `reports/figures/` no repositório mencionado, e cada número citado no texto pode ser rastreado até a célula que o calculou.

A proveniência da análise é registrada em dois níveis. No **nível prospectivo**, os notebooks documentam, em células de texto, cada decisão de preparação: as 34 variáveis selecionadas e o motivo, os três filtros e sua ordem, a manutenção das redações zeradas, a codificação ordinal do questionário e o tratamento de categorias como “Não sei”. As traduções de códigos para rótulos seguem os dicionários oficiais do INEP de cada edição, arquivados junto aos dados brutos. No **nível retrospectivo**, ficam registradas as decisões de escopo tomadas durante o projeto - em especial a exclusão da edição de 2024, discutida na Seção 3.4, e a priorização de análises exploratórias e comparativas em lugar de um modelo preditivo, ajuste feito durante a execução do trabalho.

Para reproduzir a análise, basta obter os microdados públicos no portal do INEP, posicioná-los na pasta `data/raw/` (apontada no repositório) e executar os notebooks na ordem: tratamento de cada edição, análise de cada edição e, por último, o consolidado. Os arquivos intermediários em Parquet evitam o reprocessamento do CSV bruto a cada análise - decisão que reduziu leituras de minutos para segundos e que também fica registrada como parte da proveniência do *pipeline*.

7. Conclusão

Este trabalho investigou, a partir de 8,2 milhões de registros dos microdados do ENEM de 2020 a 2023, quais fatores socioeconômicos têm maior relação com o desempenho dos candidatos. **A resposta é consistente nas quatro edições: a renda familiar é o fator de maior relação com a média geral de um candidato no exame** ($\rho \approx 0,46$), seguida do número de computadores em casa e do tipo de escola - um topo de ranking dominado por indicadores de capital econômico, com a escolaridade e a ocupação dos pais logo atrás. Quanto aos desdobramentos da pergunta de pesquisa: a hierarquia dos fatores se manteve estável no período, com variações de ρ da ordem de centésimos; a dimensão regional é relevante e persistente, com Minas Gerais liderando e o Amazonas na base em todas as edições; e as diferenças entre grupos extremos são expressivas - cerca de 150 pontos entre as faixas extremas de renda e um gap privada-pública que oscilou entre 89 e 100 pontos, sem tendência de queda, atingindo em 2023 o maior valor da série.

Esses resultados reforçam que as notas do ENEM não são produzidas em um vácuo socioeconômico: refletem, em medida considerável, condições estruturais anteriores à prova. O contraponto da rede federal - que se aproxima das privadas mesmo controlando por faixa de renda - sugere, ainda que com as ressalvas de viés de seleção, que a escola pública não está “condenada” a sempre ter um desempenho inferior.

¹<https://github.com/carlamoreeno/Project-Data-Science>

Como trabalhos futuros, seria interessante: refatorar o código do repositório, eliminando a duplicação entre os notebooks das edições por meio de funções compartilhadas; incorporar um modelo multivariado interpretável, capaz de separar a contribuição de fatores fortemente correlacionados entre si; e ampliar a série histórica para edições anteriores a 2020, além de explorar alternativas agregadas para acompanhar as edições posteriores à mudança de publicação imposta pela LGPD.

Referências

- Brasil (2018). Lei geral de proteção de dados pessoais (lgpd) – lei nº 13.709/2018. http://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/L13709.htm.
- Dutra, J. F., Firmino Júnior, J. B., and Fernandes, D. Y. d. S. (2023). Fatores que podem interferir no desempenho de estudantes no ENEM: uma revisão sistemática da literatura. *Revista Brasileira de Informática na Educação*, 31:323–351.
- Franco, J. J., Miranda, F. L. d. A., Stiegler, D., Dantas, F. R., Brancher, J. D., and Nogueira, T. d. C. (2020). Usando mineração de dados para identificar fatores mais importantes do enem dos últimos 22 anos. In *Anais do XXXI Simpósio Brasileiro de Informática na Educação (SBIE)*, pages 1112–1121, Porto Alegre, RS, Brasil. Sociedade Brasileira de Computação.
- Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP) (2024). Microdados do enem. <https://www.gov.br/inep/pt-br/aceso-a-informacao/dados-abertos/microdados/enem>. Acesso em: 12 maio 2026.